# RISC-V 动态记忆管理最终报告

软件需求工程 2026 Milestone 5 版本 0.5 2026 年 10 月 20 日

## 1 问题与完成内容

长期对话会累积旧事实、计划和后续变化。仅按相关性检索，无法说明哪条信息在当前问题和时间条件下有效。本项目实现从原始对话到结构化记忆、候选检索、状态关系、有效证据和来源问答的完整 Web 流程，保留历史以支持时间回溯。

实现采用 Python、React/ECharts、本地 MiniLM 向量与 DistilBERT 抽取式回答。系统可导入、浏览和导出 Memory，选择检索方法与时间，查看图和证据。持久记忆不因查询失效而删除。已完成 54 项自动测试和真实数据页面验证。

## 2 方法与设计选择

每句原文产生来源可追溯的记忆；部分第一人称事实抽取为结构化属性，其余以 observation 保留。时间区分会话与事件，未知不填当前时间。状态解析只比较同一人物和属性，保留并存事实，识别阶段推进和单值替代；无法消解时拒答。

MiniLM 输出归一化 384 维向量，单条编码最多 128 token。三方法共用同一 DistilBERT ONNX int8 回答器，输出最多 30 token 的一个原文跨度。Full Text 遍历完整历史的 384-token 窗口，重叠 96 token；没有预先按相关性丢弃窗口。它属于全文抽取式基线，不等同于长上下文生成式 LLM。

普通 Vector 与 Dynamic Vector 的 Top-K 候选逐题完全相同，K=10；差异为是否启用状态解析。回答器不读取 gold。配置、权重 revision、代码/数据哈希、问题清单、逐题答案与耗时均随包保存。

## 3 数据、划分和评分协议

公开 LoCoMo 固定版本为 3eb6f2c585f5e1699204e3c3bdf7adc5c28cb376，原文件 SHA-256 以数据清单为准。本轮依据上游顺序自主选择六段；用户确认选段与 4＋2 划分均由团队决定：

| 部分 | 对话 ID | 用途 |
| --- | --- | --- |
| 开发 | conv-26、30、41、42 | 模块与案例验证，主方法各一遍 |
| 项目留出 | conv-43、44 | 固定配置下各三次重新推理 |
| 本轮未评测 | conv-47、48、49、50 | 保留原始文件，供扩展 |

六段共 156 个会话、3435 轮，生成 10207 条 Memory。普通可评测 QA 共 885 题；本轮每段每个 category 1－4 按问题 SHA-256 排序取前两题，缺少题型时不补挑，得到开发 30、留出 16 题。完整题单另存，未评测部分不计成绩。对抗 category 5 的特殊答案协议未纳入本表。

动态诊断另有 12 道基于真实轮次的自建问题、10 个有序关系对。标注以原文语义显式编写，保存理由和全文来源，未调用系统关系函数生成答案，但仅为单次 AI 辅助标注，尚无独立人工复核，不能视为课程黄金标注。多项问题按可接受短片段诊断，不衡量列表完整性。

F1 为英文 token 多重集合得分；Recall@10 将前十条 Memory 映射至来源轮次后去重，再对有证据题宏平均。动态准确率按全部黄金有序关系对微平均，漏召回和歧义计错。全文没有候选检索评分，标 N/A。动态标准未提供的普通 QA 不计算关系准确率。

这轮是项目留出验证。已有部分留出原文被查看以制作案例，不宣称严格盲测；未依据测试分数继续调规则。该划分可作为本项目记录的评测划分，无需等待老师指定；自建标签人工复核或评分规则变更后，应重跑受影响实验。

## 4 实验结果

下表是同一 16 道留出题的三次均值，非 48 道不同问题。随机种子记为 17、23、41，ONNX CPU 无采样，三次答案一致，F1 和召回的样本标准差均为 0；不能据此宣称统计显著。延迟含首题缓存构建，受同机负载影响，只作本机参考。

| 方法 | QA F1 | 候选召回 | 有效召回 | 秒/题 |
|---|---|---|---|---|
| Full Text | 0.000 | N/A | N/A | 15.21 |
| Vector RAG | 0.091 | 0.536 | 0.536 | 0.42 |
| Dynamic Vector | 0.082 | 0.536 | 0.474 | 0.42 |

本轮留出 QA F1：Full Text=0.000，Vector RAG=0.091，Dynamic Vector=0.082。动态方法在 16 题中有 4 题未进入神经回答；候选不变时，解析过滤与拒答会改变答案覆盖率。该小样本结果不支持通用性能提升结论。

开发集 30 题使用同一设置，结果另列，未与留出混算：

| 方法 | 开发 F1 | 候选召回 | 有效召回 |
|---|---|---|---|
| Full Text | 0.040 | N/A | N/A |
| Vector RAG | 0.197 | 0.544 | 0.544 |
| Dynamic Vector | 0.118 | 0.544 | 0.494 |

自建动态诊断的 QA F1=0.281，候选召回=0.708，有效召回=0.431，关系准确率=0.400（4/10）。它与上述普通问答题单不同，只能评价这些明确标注的案例。课程动态测试成绩当前不可由此推定。

来源：src/results/real/summary.json、各 seed 的 predictions/config/metrics 文件、dynamic-diagnostic-metrics.json。汇总器核对普通向量和动态向量逐题候选 ID 一致，并在预测缺题时拒绝汇总。人工回归 9 题的满分仅用于工程回归，不放入本主表。

## 5 案例与误差分析

真实阶段案例：conv-26 D2:8 为研究收养机构，D13:1 为提交申请，D19:1 为通过面试。当前查询使用 D19:1，历史查询 as_of=2023-06-01 使用 D2:8，前序记忆仍可查看。浏览器已实际运行并保留来源图与查询 JSON。

部分答案命中：conv-44-qa-050。问题“What is a skill that Audrey learned to take care of her dogs?”；参考答案“Grooming”；证据 D16:2, D17:4。向量答案“grooming course”，F1=0.667，候选召回=0.000；动态答案“grooming course”。

黄金证据漏召回：conv-44-qa-058。问题“What did Audrey eat for dinner on October 24, 2023?”；参考答案“sushi”；证据 D25:14。向量答案“some snack”，F1=0.000，候选召回=0.000；动态答案“some snack”。

动态拒答：conv-43-qa-001。问题“What are John's goals for his career that are not related to his basketball skills?”；参考答案“get endorsements, build his brand, do charity work”；证据 D6:15, D11:17。向量答案“Do you have any big goals”，F1=0.143，候选召回=0.500；动态答案“Cannot determine reliably from the available evidence.”。

候选漏召回时，后续状态解析无法补回未找到的证据；因此分别报告候选与有效召回。召回到证据却回答不对，可能来自单跨度模型、跨窗口概率比较、时间换算或列表综合能力不足。动态方法遇到未知时间、计划或冲突会拒答，保守策略能够说明不确定性，也可能排除仍有用的上下文。

全文留出 F1 为 0.000，当前跨窗口强制作答配置未取得有效 QA 成绩。单窗口 SQuAD 模型的跨窗口分数可能偏向无关跨度，这个弱基线不能代表生成式长上下文模型。

当前语义规则主要覆盖收养阶段、少量居住/工作、兴趣和宠物所有状态，无法可靠解释通用代词、否定、第三人称及多跳。自建关系标注也可能有歧义。上述误差保留在逐题文件中，本轮没有为改善留出成绩改写标签或挑选题目。

## 6 复现、过程与交付

推荐 Python 3.12，依赖固定为 ONNX Runtime 1.23.2、tokenizers 0.22.2、NumPy 2.5.4。模型权重随包，首次安装依赖后可离线运行。根目录 run.bat 启动真实数据与两个本地模型；run-basic.bat 是无神经依赖备用方式。详细复现见 M5-实验协议与复现.md。

在 src 目录执行 prepare_data.py、prepare_dynamic.py、run_benchmarks.py；动态诊断按协议另行预测并评分，随后运行 summarize_results.py。预测命令仅读允许的原文和问题，评分器单独读取 gold。文件记录数据、问题、模型、代码哈希及每次开始时间，原始材料不覆盖。本轮全量 Schema 校验发现 61 条句尾空白产生的空记忆，0.5.1 已修复并新增回归测试。全部向量/动态实验已重跑。全文神经推理保留 0.5.0 的原始运行，78 条预测的全文上下文哈希逐条核对与修复后完全一致，回答模型代码和原始数据亦未变；对应旧代码与证明保存在 process/archive/0.5.0-inference 和 whitespace-fix-audit.json。该修复是数据清理缺陷处理，未根据留出答案调参。

原仓库 M1/M2、两份真实纪要、看板与模板完整保留；本地实现过程记录说明两轮原型及真实模型迭代，不代替成员会议。文档、源码、模型、Memory、逐题结果、测试、截图、PPTX 和讲稿均已提供。GitHub 推送、成员签字、课堂展示与邮件回执尚未执行，不伪造为已完成。

## 7 结论与后续验收

项目完成可运行的动态记忆工程闭环，并实际比较全文、向量和动态解析。阶段与历史案例可以解释有效证据，但本轮小样本和有限语义规则不足以证明普遍优于基线。下一步应扩展语义抽取，降低无关不确定记忆造成的拒答，并对自建动态标注进行独立人工复核。

正式提交前须完成自建标签复核并核对评分定义，填写真实团队编号，并完成真实成员评审与排练。若课程要求生成式模型，应为全部方法替换相同回答器并重跑，不能沿用抽取式模型数字冒称生成式成绩。

参考：课程项目 PDF 第 9–13 页；LoCoMo（Maharana 等，ACL 2024），github.com/snap-research/locomo；MiniLM 与 DistilBERT 上游模型卡和 Xenova ONNX 文件。数据许可与模型许可全文及引用随包保留。